

دوره دیتا ساینس کاربردی

XX

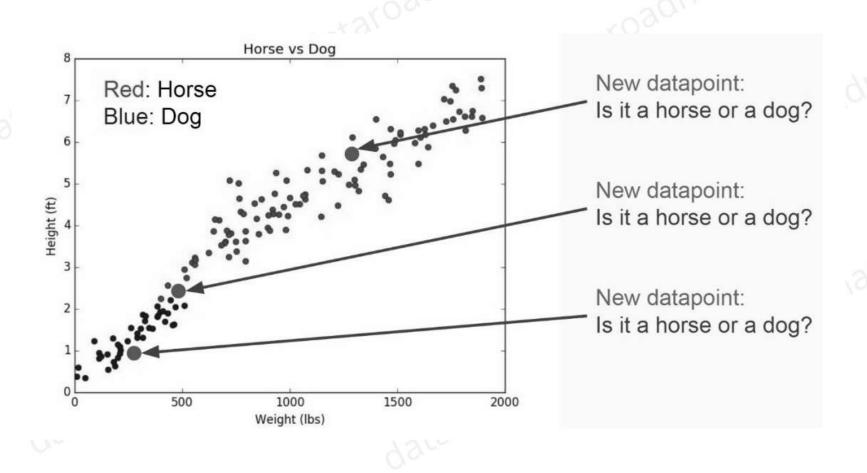
Machine Learning

K Nearest Neighbors

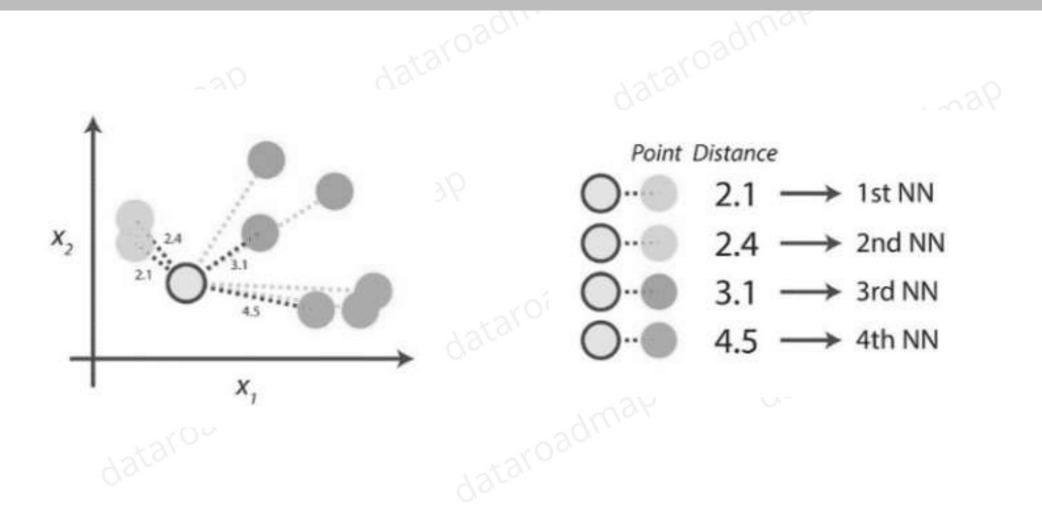
• dataroadmap مدرس: مونا حاتمی

جلسه هفتم

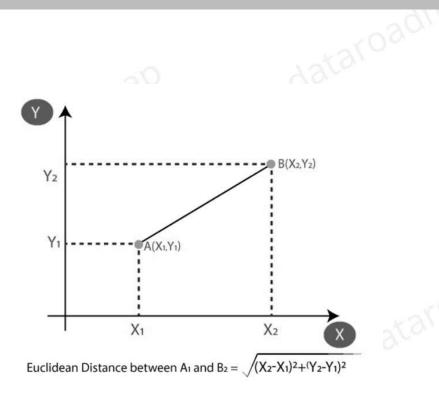
K Nearest Neighbors (KNN) Supervised Learning

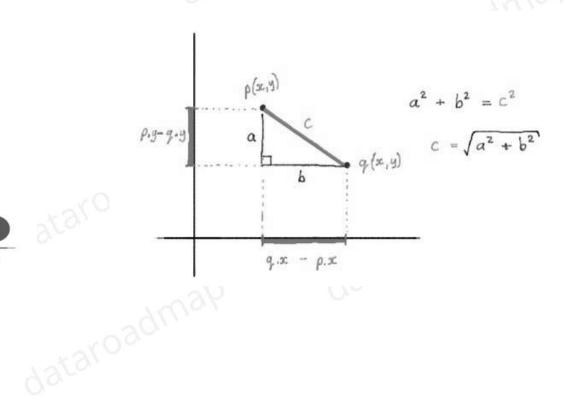


K Nearest Neighbors (KNN)

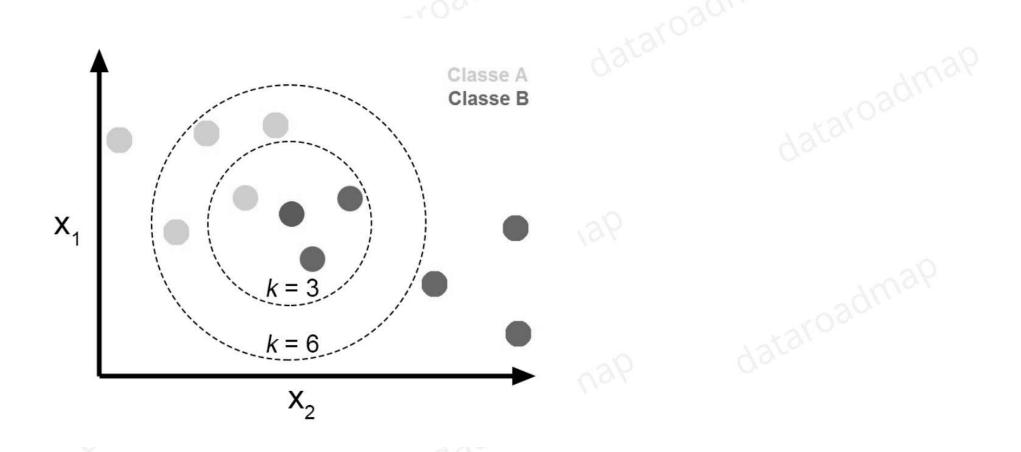


Euclidean Distance





KNN, K Number



KNN, Pros & Cons

مزایا این روش: ساده است. چندین دسته را دربر میگیرد.

معایب این روش: برای دیتاست های بزرگ خیلی هزینه بر است. روش نامناسب برای دیتاست هایی با پارامتر زیاد است.

Read the Data

```
M import pandas as pd
```

The Data ¶

```
M df = pd.read_csv('preprocessed_dataset.csv')
```

M df.head()

[3]:

	Unnamed: 0	PayloadMass	Flights	GridFins	Reused	Legs	Block	ReusedCou
0	0	6104.959412	- 1	0	0	0	1.0	
1	1	525.000000	1	0	0	0	1.0	
2	2	677.000000	1	0	0	0	1.0	

Non- Null

```
M df.info()
  <class 'pandas.core.frame.DataFrame'>
  RangeIndex: 90 entries, 0 to 89
  Data columns (total 89 columns):
                                            Non-Null Count Dtype
      Column
                                                            int64
      Unnamed: 0
                                            90 non-null
   0
                                            90 non-null
                                                            float64
      PayloadMass
      Flights
                                            90 non-null
                                                           int64
      GridFins
                                            90 non-null
                                                           int64
   4
                                            90 non-null
      Reused
                                                            int64
                                            90 non-null
                                                            int64
   5
      Legs
                                            90 non-null
                                                            float64
      Block
      ReusedCount
                                            90 non-null
                                                            int64
      Class
                                            90 non-null
                                                            int64
                                            90 non-null
                                                            int64
      Orbit ES-L1
   10 Orbit_GEO
                                            90 non-null
                                                            int64
   11 Orbit GTO
                                            90 non-null
                                                            int64
   12 Orbit_HEO
                                            90 non-null
                                                            int64
                                            90 non-null
   13 Orbit ISS
                                                            int64
```

Define X, y

```
X=df.drop('Class',axis=1)
y=df['Class']
```

Tataroadi

dataroadmap

dataroadmap

*aroadman

Train set- Test set in sklearn library

Train the model

```
In [8]: # K Nearest Neighbors classification algorithm
    from sklearn.neighbors import KNeighborsClassifier

In [9]: # knn = KNeighborsClassifier(n_neighbors=10)

In [10]: # knn.fit(X_train,y_train)

Out[10]: KNeighborsClassifier(n_neighbors=10)
```

Prediction

VS

y_test

```
In [11]: N predictions = knn.predict(X_test)
         M predictions
In [12]:
   Out[12]: array([0, 1, 1, 0, 1, 0, 1, 1, 1, 0, 1, 1, 1, 1, 1, 0, 1], dtype=int64)
In [13]: ⋈ y_test
   Out[13]: 50
            31
            Name: Class, dtype: int64
```

Evaluation (TP, FP, TN, FN)

Confusion Matrix

PREDICTIVE VALUES POSITIVE (1) NEGATIVE (0) TP FN NEGATIVE (0) FP TN

dataroadma

Confusion Matrix Error I & Error II

Accuracy = (TP+TN)/(TP+FP+FN+TN)

دقت Precision = TP/(TP+FP)

بازخوانی Recall = TP/(TP+FN)

F1 Score = 2*(Recall * Precision) / (Recall + Precision)

Accuracy Score

```
In [16]:
In [17]: N accuracy_score(y_test, predictions, normalize=False)
   Out[17]: 10

► accuracy_score(y_test, predictions, normalize=True)

In [18]:
   Out[18]: 0.55555555555556
```

Classification Report

	precision	recall	f1-score	support
0	0.40	0.29	0.33	7
1	0.62	0.73	0.67	11
accuracy			0.56	18
macro avg	0.51	0.51	0.50	18
weighted avg	0.53	0.56	0.54	18

Grid Serach

```
M knn_1 = KNeighborsClassifier()
    Init signature:
    KNeighborsClassifier(
H
        n_neighbors=5,
        weights='uniform',
H
        algorithm='auto',
        leaf_size=30,
        p=2,
        metric='minkowski',
        metric_params=None,
M
```

Grid Serach

Tune Hpyerparameters

Result

```
In [35]: M predictions_1 = knn_1.predict(X_test)
In [36]: M confusion_matrix(y_test,predictions_1)
   Out[36]: array([[2, 5],
                   [2, 9]], dtype=int64)
In [37]:  accuracy score(y test,predictions 1, normalize=False)
   Out[37]: 11
In [38]:  accuracy_score(y_test,predictions_1, normalize=True)
   Out[38]: 0.61111111111111112
```

Assignment:

تمرین:

کدهای ارائه شده در درس را در نوتبوک جدیدی انجام داده و در صورت نیاز از نوتبوک هفته هفتم استفاده کنید.

برای تمرین بیشتر جلسه دهم دوره منتورینگ دیتاساینس را در کانال یوتیوب ملاحظه کنید.

رزومه خود را آپدیت کرده و مهارتهایی که تا به امروز فراگرفته اید را اضافه کنید.